

Predicción de Precios de Alquiler en el AMBA: Análisis Geoespacial y Correlación con Amenidades

Tomas, Diaz
Universidad de San Andres
Buenos Aires, Argentina
tdiaz@udesa.edu.ar

Abstract—Este estudio utiliza un modelo basado en XGBoost para comparar las distribuciones de precios de alquiler en el AMBA y analizar patrones geoespaciales. A través de estas distribuciones, se buscó identificar correlaciones con la presencia de amenities, como gimnasio, pileta y calefacción. Los resultados muestran que se encontraron patrones que coinciden con las diferencias en los precios según las amenities, aunque estos no fueron suficientes para ser concluyentes. Estos hallazgos sugieren que, si bien el modelo es prometedor, se requiere un análisis más profundo para confirmar las correlaciones observadas.

Index Terms—machine learning, house prediction, XGBoost

I. INTRODUCCIÓN

El mercado inmobiliario del Área Metropolitana de Buenos Aires (AMBA) presenta desafíos únicos debido a su complejidad geográfica y a la inestabilidad económica característica de Argentina. A lo largo de su historia, el país ha atravesado numerosas crisis económicas y devaluaciones, lo que ha provocado fluctuaciones abruptas en los precios de bienes y servicios. Este contexto inflacionario, combinado con la diversidad del mercado inmobiliario, dificulta la tarea de predecir precios de forma precisa y confiable para propiedades.

La motivación para abordar este problema surge de la necesidad de contar con una herramienta que ayude a estimar los precios de manera más precisa en un mercado tan volátil como el nuestro. Pero no se trata solo de predecir números; la idea también es descubrir patrones espaciales y tendencias que puedan ser útiles para entender mejor cómo se comporta el mercado, tomar decisiones más informadas, planificar inversiones, e incluso aportar a la planificación urbana de forma más estratégica.

Se desarrolló un modelo basado en XGBoost que toma como entrada un conjunto de datos que incluye tanto variables numéricas (superficie total de las propiedades, la cantidad de ambientes) como categóricas (gimnasio, calefacción, entre otras). Además, incorpora datos de localización que reflejan una ubicación aproximada de las propiedades. Utilizando este dataset, se tuvo el objetivo de predecir el precio de alquiler en pesos constantes.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

El conjunto de datos utilizado para este proyecto contiene información detallada sobre propiedades en el AMBA y fue obtenido de publicaciones en Mercado Libre durante los años 2021 y 2022. En total, el dataset original incluía 278,725

ejemplos. Después de aplicar los preprocesamientos necesarios y filtrar valores extremos, se dividió en 3 subconjuntos:

Entrenamiento	Validación	Test
215477	53870	4921

TABLE I

NUMERO DE MUESTRAS PARA ENTRENAMIENTO, VALIDACIÓN Y TEST

El dataset original contaba con 45 características. Las categorías incluidas en el modelo fueron las siguientes: STotalM2, SConstrM2, Antigüedad, Dormitorios, Banos, Ambientes, Cocheras, AccesoInternet, Gimnasio, Pileta, Calefaccion, AireAC, SalonDeUsosMul, Laundry, Seguridad, Amoblado, ITE-TIPO-PROD, LONGITUDE y LATITUDE.

La principal razón para omitir las otras categorías fue la falta de información útil para el modelo. Las variables binarias no consideradas no cumplían con mis criterios de información (al menos 5% de valores positivos y menos de 10-12% de valores NaN para variables no relevantes, y al menos 3% de positivos y como máximo 12-15% de NaN para las relevantes). Además, algunas variables como tipo propiedad solo tenían un valor y no aportaban información, y id_grid era redundante con las coordenadas. Las categorías de estado, ciudad y barrio, aunque podrían haber aportado algo de información, se eliminaron porque la mayoría de los valores eran iguales para el mismo ID, lo que podría afectar la precisión del modelo en la delimitación de barrios.

El preprocesamiento de las variables incluyó transformaciones específicas para garantizar la calidad de los datos y su adecuación al modelo predictivo.

Para la columna de antigüedad, se imputaron valores faltantes, se corrigieron extremos, y valores inválidos bajo cierto criterio: Cualquier valor mayor a 145 años, se calcula la moda del id, si ese valor sigue siendo mayor a 145, se reemplaza por 0. También consideramos valores entre 2024 y 2029 como 0 (edificios en construcción).

En cuanto a las superficies, se aplicó una transformación logarítmica ($\log(1 + x)$) para reducir el impacto de valores extremos. Además, se ajustó SConstrM2 para asegurar que no excediera el valor de STotalM2, manteniendo la coherencia de los datos. Para estas categorías, los valores no validos (NaNs o números negativos) se computaron como 0.

Las variables categóricas, como Dormitorios, Banos, y Ambientes, fueron tratadas imputando los valores faltantes

con la moda calculada dentro de cada id-grid (polígono geoespacial), y para valores inválidos (valores negativos), se los considero 0. Posteriormente, se aplicó también la transformación logarítmica ($\log(1+x)$). La variable ITE-TIPO-PROD, que indica el tipo de propiedad, fue convertida en variables indicadoras (one-hot encoding).

Un comentario que puede aclarar dudas es que, si bien sabemos que no es necesario aplicar estas transformaciones a las categorías porque el modelo de XGBoost puede capturar estas transformaciones de manera implícita. No obstante, estas categorías tienen valores muy grandes y una distribución muy sesgada por valores extremos, por consecuencia, pensamos que una transformación como $\log(x+1)$ podía ayudar a estabilizar la varianza, reduciendo el efecto de dichos valores.

Las variables binarias, como AccesoInternet, Gimnasio, y Pileta, fueron mapeadas de valores de texto (sí/no) a valores numéricos (1/0). Los valores faltantes en estas columnas se imputaron utilizando la moda de cada columna del dataset para garantizar consistencia.

Se realizó un filtrado de valores extremos en el conjunto de datos, eliminando aquellos ejemplos con precios mayores a 400,000. Este umbral fue seleccionado porque consideramos que precios más altos son atípicos o no representan adecuadamente el mercado general, además de empeorar significativamente el rendimiento del modelo. Fundamentamos esta decisión en que los valores menores a nuestro umbral constituyen el 98.4% del conjunto de datos, con una media de aproximadamente 80,000. Por esta razón, precios superiores a 1,000,000 fueron catalogados como valores espurios o posiblemente erróneos. Sin embargo, reconocemos que algunos valores en este rango podrían proporcionar información útil sobre un subconjunto específico de propiedades. Pero priorizamos un modelo que rinda bien sobre la gran mayoría de los datos en lugar de incluir valores que podrían ser outliers.

Finalmente, aunque las transformaciones logarítmicas ayudaron a normalizar muchas de las variables, las características restantes fueron escaladas utilizando StandardScaler, asegurando que estuvieran en rangos comparables.

III. METODOLOGÍA

El modelo principal utilizado en este proyecto es XGBoost (Extreme Gradient Boosting), un modelo basado en árboles de decisión que combina técnicas de boosting para mejorar el rendimiento y la capacidad predictiva. Este modelo fue seleccionado por su capacidad para manejar conjuntos de datos grandes, capturar relaciones no lineales complejas entre las variables, y su robustez frente a datos heterogéneos.

El rendimiento del modelo y la capacidad de predecir correctamente los precios de propiedades depende de nuestra función de costo. En nuestro caso, utilizamos el Raíz del Error Cuadrático Medio (RMSE), mide la discrepancia entre las predicciones del modelo y los valores reales:

$$L(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1)$$

donde y_i son los valores reales y $\hat{y}_i$ son las predicciones del modelo.

Además, tenemos un término de regularización para nuestro modelo. Este controla la complejidad del mismo para evitar el sobreajuste. La regularización en XGBoost incluye penalizaciones en la cantidad de hojas de los árboles (T) y en la magnitud de los pesos:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2)$$

donde w_j son los pesos de las hojas, γ es el costo asociado por agregar una hoja, y λ controla la magnitud de los pesos (w_j).

El objetivo final del modelo es minimizar:

$$\text{Obj} = L(y, \hat{y}) + \sum_{t=1}^T \Omega(f_t) \quad (3)$$

donde $L(y, \hat{y})$ es la función de pérdida, $\Omega(f_t)$ es el término de regularización para el árbol t , T es el número total de árboles en el modelo.

XGBoost combina el rendimiento y transparencia de árboles de decisión, regularización efectiva, y optimización basada en gradientes, lo que lo convierte en una herramienta ideal para abordar problemas como el nuestro. Su capacidad para generalizar en un contexto tan complejo como el mercado inmobiliario argentino permitió obtener resultados precisos.

IV. DESARROLLO EXPERIMENTAL

Primero, cargamos y preprocesamos los datos, para luego dividirlos en tres subconjuntos: entrenamiento, validación y test (este último no corresponde al test proporcionado por la cátedra, sino que es un conjunto separado). Esta división se muestra en la Tabla 1.

A continuación, creamos un modelo base con parámetros elegidos de manera aleatoria, pero dentro de un rango razonable. Entrenamos el modelo y evaluamos las predicciones en los subconjuntos de entrenamiento y validación utilizando nuestras métricas principales: RMSE (Raíz del Error Cuadrático Medio), que se expresa en la Ecuación 1, y R^2 (Coeficiente de Determinación). El R^2 mide qué tan bien las predicciones explican la variabilidad de los datos, comparándolo a su vez con el modelo más simple posible (la media para toda predicción) y su fórmula es:

$$R^2 = 1 - \frac{\sum_i (y_i - \bar{y})^2}{\sum_i (y_i - \hat{y}_i)^2} \quad (4)$$

donde y_i son los valores reales, $\hat{y}_i$ son las predicciones del modelo, y $\bar{y}$ es la media de los valores reales.

Después, seleccionamos los hiperparámetros que deseamos optimizar, que incluyen:

Estos valores fueron elegidos para cubrir un rango que va desde los valores predeterminados del modelo hasta valores más altos o bajos, con el fin de explorar su impacto en el rendimiento. Para encontrar la combinación óptima de estos

Hiperparámetro	Valores
n_estimators	200, 500, 1000
learning_rate	0.01, 0.05, 0.1
max_depth	7, 9, 12
subsample	0.8, 1.0
gamma	0, 1, 3
min_child_weight	1, 3

TABLE II
HIPERPARÁMETROS A OPTIMIZAR

hiperparámetros, realizamos un Grid Search y evaluamos cada combinación utilizando validación cruzada con 2 folds para hacer el proceso más robusto.

Una vez identificados los mejores hiperparámetros, entrenamos nuevamente el modelo con estos parámetros optimizados. Esta vez, evaluamos el rendimiento en los subconjuntos de entrenamiento y validación, pero con una validación cruzada de 5 folds para tener una estimación más precisa del desempeño del modelo.

Finalmente, utilizamos el conjunto de test para simular el rendimiento del modelo con datos completamente nuevos. Realizamos las predicciones sobre el conjunto de test, calculamos el RMSE y R^2 sin validación cruzada, y guardamos las predicciones generadas para su análisis posterior.

V. RESULTADOS Y DISCUSIÓN

Como punto de partida, entrenamos un modelo base con parámetros elegidos siguiendo convenciones razonables. Los resultados del baseline para las métricas principales, RMSE y R^2 , se presentan en la Tabla 3. El gráfico en la Figura 1 muestra las curvas de pérdida para el conjunto de entrenamiento y validación, lo que permite observar la convergencia del modelo inicial.




Fig. 1. Train y Validation Loss de modelo base

El modelo base logró un R^2 bastante alto tanto en entrenamiento como en validación, lo que indica que capturó adecuadamente las relaciones entre las características y los precios de alquiler. Además, por lo que podemos ver de la curva de la función de pérdida no parece que exista un

sobreajuste del modelo ya que notamos una convergencia suave al final del entrenamiento. Estos resultados iniciales destacan que el modelo base ya es sólido por sí mismo. Sin embargo, para garantizar que este buen rendimiento no sea producto de un ajuste específico a los datos y para hacer el modelo más robusto, decidimos optimizar los hiperparámetros mediante un Grid Search.

Métrica	Baseline	Modelo Optimizado (CV 5-fold)
RMSE (Train)	6421.62	7802.96
RMSE (Validation)	8198.17	12092.74
R^2 (Train)	0.9751	0.9633
R^2 (Validation)	0.9581	0.9087

TABLE III
COMPARACIÓN DE RMSE Y R^2 ENTRE EL MODELO BASELINE Y EL MODELO OPTIMIZADO

Luego de realizar un ajuste de hiperparámetros utilizando Grid Search y validación cruzada, entrenamos el modelo con los hiperparámetros óptimos seleccionados. Los resultados obtenidos se resumen en la Tabla 3, donde se comparan las métricas entre el baseline y el modelo optimizado. Aunque el rendimiento del baseline en términos de RMSE y R^2 es ligeramente superior, el modelo optimizado logró resultados consistentes en todos los folds de la validación cruzada, lo que sugiere una mayor robustez.




Fig. 2. Train y Validation Loss de modelo optimizado

La Figura 2 presenta las curvas de pérdida (train y validation) del modelo optimizado. Se observa una curva casi idéntica, con convergencia estable y suave, con diferencias menores en los datos en los que termina. Además, al evaluar mediante validación cruzada, se verificó que los resultados fueron consistentes entre los pliegues, confirmando que el modelo generaliza bien y no depende de una partición específica de los datos. Esto nos permitió asegurar que su desempeño sea sólido y estable en distintos subconjuntos de los datos, algo que nos ayudó a generar un modelo más confiable para su aplicación en datos no vistos.

Finalmente, al evaluar el modelo final sobre nuestro propio set (no el proporcionado por la cátedra), se obtuvo el siguiente

RMSE (6943.798) y R^2 (0.967). Lo que muestra que nuestro modelo es correcto cuando tiene que predecir datos que no vio antes. Esto se debe al enfoque y la persistencia de usar GridSearch y Cross Validation a pesar de tener un modelo base con mejores métricas.

Para analizar visualmente el desempeño del modelo optimizado, la Figura 3 muestra un gráfico de dispersión que compara las predicciones frente a los valores reales sobre todo el conjunto de datos. Se observa que las predicciones del modelo se alinean bien con los valores reales, aunque existen algunos errores dispersos en los extremos, lo cual puede deberse a outliers en los datos o a limitaciones del modelo.




Fig. 3. Mapa de dispersion, predicciones vs etiquetas (todo el dataset)

Por otro lado, en la Figura 4 se grafican los residuos del modelo optimizado. La distribución de los residuos se asemeja a una exponencial, pero tiene una gran cantidad de valores alrededor de cero. Sin embargo, se identifican algunos valores residuales altos, posiblemente asociados con ejemplos difíciles o mal etiquetados.




Fig. 4. Grafico de residuos (todo el dataset)

Las métricas obtenidas y las visualizaciones muestran que el modelo es capaz de generalizar bien a datos no vistos, lo que lo convierte en una herramienta adecuada para predecir precios de alquiler en el AMBA. Sin embargo, existe margen para futuras mejoras, especialmente en el manejo de outliers.

Una vez realizado el modelo, lo implementamos en lo que nos compete, la distribución geoespacial de los precios de alquileres sobre el AMBA. Los gráficos que muestran la distribución de los precios reales y la distribución de los precios predichos por el modelo son bastante similares. Esto tiene sentido, ya que los buenos resultados obtenidos por el modelo en términos de RMSE y R^2 indican que las predicciones realizadas se alinean bien con los valores reales. La similitud entre las distribuciones sugiere que el modelo ha aprendido correctamente las tendencias y patrones del conjunto de datos.




Fig. 5. Distribucion real de precios




Fig. 6. Distribucion predecida por modelo

En cuanto a la detección de patrones de precios y su posible correlación con las amenidades, decidimos, para hacerlo más representativo, realizar el análisis por zonas (Capital Federal, Bs. As. Oeste, Bs. As. Sur, Bs. As. Norte).

Se llegó a la conclusión de que, en las zonas donde existían patrones claros de diferencia de precios, el valor de las propiedades con amenities experimentaba un aumento notable.

Aunque esta observación es relevante, no es concluyente, ya que en algunas regiones no se encontraron patrones claros, o el patrón observado no permitió identificar de manera eficiente solo los valores significativamente diferentes.




Fig. 7. Distribucion de la zona sur del AMBA y los patrones detectados




Fig. 8. Porcentaje de viviendas con diferentes amenities (para toda la zona Bs. As. Sur)




Fig. 9. Porcentaje de viviendas con diferentes amenities (para las propiedades dentro del patrón)

VI. CONCLUSIÓN

El modelo basado en XGBoost mostró un buen rendimiento, generalizando bien a datos no vistos, a pesar de que sus métricas fueron ligeramente inferiores en comparación con el modelo base. Esto se debió a la optimización de hiperparámetros y la validación cruzada, lo que garantizó que el modelo fuera robusto y no estuviera sobreajustado a los datos de entrenamiento.

Además, al comparar las distribuciones de precios de alquiler en el AMBA, se detectaron patrones geoespaciales relacionados con la presencia de amenities. Aunque estos patrones indicaron una posible correlación, los resultados no fueron suficientes para ser concluyentes. Esto sugiere que, aunque el modelo es efectivo para identificar tendencias, se requiere un análisis más profundo para confirmar estas relaciones de manera más robusta.

VII. TRABAJO A FUTURO

Para trabajos futuros, se podría considerar incorporar los valores de estado ciudad y barrio como características adicionales, ya que podrían mejorar la precisión del modelo. Tal vez, al contar con una mayor granularidad en la ubicación de las propiedades, podríamos capturar patrones espaciales más específicos y mejorar las predicciones.

También, sería interesante explorar la inclusión de valores entre 400,000 y 1,000,000, ya que podrían aportar información valiosa sobre un subconjunto del mercado inmobiliario, como propiedades de lujo o ubicadas en zonas exclusivas, desarrollando un modelo más inclusivo y flexible.

Además, existían otros hiperparámetros que habrían sido interesantes de optimizar, como la regularización por parte de los pesos (alpha), una exploración más profunda de estos en general, podría mejorar aún más el rendimiento del modelo para datos. Sin embargo, debido a limitaciones computacionales, decidimos centrarnos en los hiperparámetros principales.

REFERENCES

- [1] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. Retrieved from <https://scikit-learn.org/stable/> (Accessed: 2024-12-11).
- [2] Jordahl, K., et al. (2020). GeoPandas: Python tools for geographic data. Retrieved from <https://geopandas.org/> (Accessed: 2024-12-11).
- [3] Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson Education.
- [4] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.